

一. 导入数据

1.1. 从上海本地宝获取上海无症状感染者从 3.1 到 5.15 的数据记入 excel, 读取 excel 数据并转换为时间序列。

```
library(xlsxjars)
library(rJava)
library(xlsx)
#导入数据
mydata <- read.xlsx("D:\\MathModeling\\RFunction\\上海新增3.1-5.13.xlsx",1)
no_sym <- mydata[,3]
no_sym=ts(no_sym,start=1)
```

图 1.1: 读入数据

二. 拟合 ARIMA 模型前期准备

2.1. 数据平稳化




图 2.1.1: 无症状感染者的时序图

根据无症状感染者的时序图, 数据明显先增后减, 具有不同的均值, 因此无症状感染者时间序列为非平稳。考虑对数据进行差分运算。




图 2.1.2: 一阶差分无症状感染者的时序图

Augmented Dickey-Fuller Test

```
data: diff(no_sym)
Dickey-Fuller = -2.989, Lag order = 4, p-value = 0.1724
alternative hypothesis: stationary
```

图 2.1.3: 一阶差分无症状感染者 ADF 检验

单纯通过时序图，难以区分是否平稳，进行单位根检验 $p = 0.1724 < 0.05$ ，一阶差分的无症状感染者时间序列不平稳，进行二阶差分运算。




图 2.1.4: 二阶差分无症状感染者的时序图

2.2. 白噪声检验

```
Box-Pierce test

data: df2
X-squared = 7.6598, df = 1, p-value = 0.005646

Box-Pierce test

data: df2
X-squared = 7.6598, df = 1, p-value = 0.005646

Box-Pierce test

data: df2
X-squared = 7.6598, df = 1, p-value = 0.005646
```

图 2.2.1: LB 检验

延迟 6, 12, 18 阶的统计量的 LB 统计量的 P 值 $p = 0.005646 < 0.05$, 二阶差分后的无症状感染者的时间序列不是白噪声序列, 具有建模价值。

三. 拟合 ARIMA 模型

3.1. 通过自相关, 偏相关函数对模型初步判断




图 3.1.1: 自相关函数




图 3.1.2: 偏相关函数

根据自相关函数和偏自相关函数图, 可以认为自相关函数 5 阶截尾, 偏自相关函数 5 阶截尾, 建立疏系数模型 $ARIMA((1,1,0,0,1), 2, (1,1,1,0,1))$, 由于个别参数未通过显著性检验, 对模型进行调整, 最终建立了 $ARIMA(2,2, (0,0,1))$ 模型。

```
Coefficients:
      ar1      ar2  ma1  ma2      ma3
    -0.6551 -0.7242   0    0  -0.3708
s.e.   0.1084   0.1099   0    0   0.1655

sigma^2 estimated as 2078527:  log likelihood = -626.44,  aic = 1258.88
```

模型 : $\nabla^2 x_t = -0.6651 * x_{t-1} - 0.7242 * x_{t-2} + \varepsilon_t - 0.3708 \varepsilon_{t-3}$
 $\varepsilon_t \sim N(0, 2078527)$

四. 对建立的ARIMA模型进行评估

4.1. 对残差进行白噪声检验

```
data: model1$residual
X-squared = 2.0438, df = 6, p-value = 0.9156
```

Box-Pierce test

```
data: model1$residual
X-squared = 5.299, df = 12, p-value = 0.9472
```

Box-Pierce test

```
data: model1$residual
X-squared = 6.9157, df = 18, p-value = 0.9908
```

图 4.1.1: 残差白噪声检验

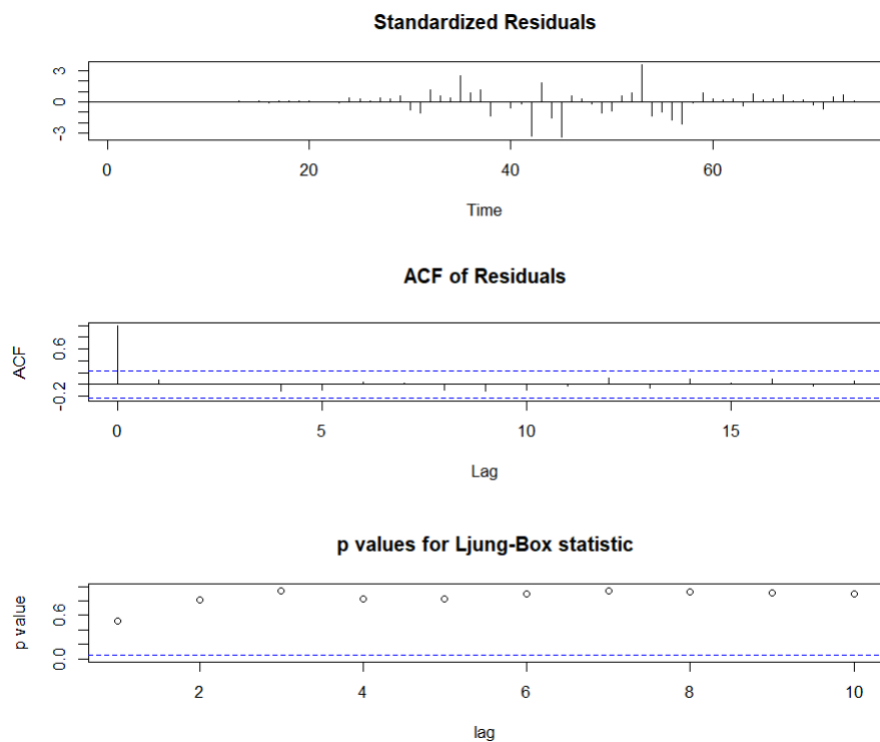


图 4.1.2: 残差性质图

延迟 6, 12, 18 阶的残差的 LB 检验的 P 值都在 0.9 以上, 显著 >0.05 , 且残差的自相关函数没有显著的自相关性, 因此残差是白噪声序列, 观察标准化残差图, 标准化残差存在中间大两侧小的特征, 似乎存在波动聚集性, 需进一步检验。

4.2 残差正态检验

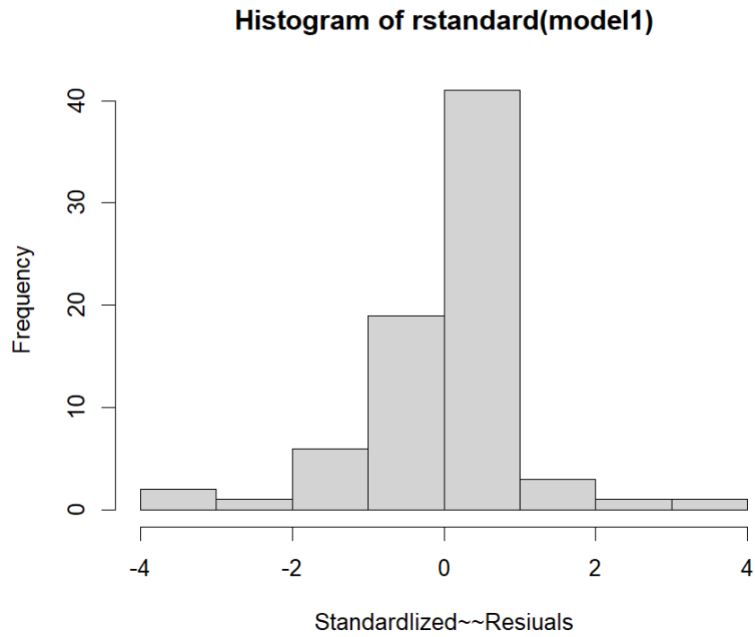


图 4.2.1：标准化残差直方图




图 4.2.2：残差正态 QQ 图

标准化残差直方图呈现尖峰厚尾，为偏态分布，且 QQ 图显示两侧都明显偏离正态分布，初步判断该时间序列为非正态分布

```
> shapiro.test(residuals(model1))

Shapiro-Wilk normality test

data:  residuals(model1)
W = 0.86009, p-value = 8.107e-07
```

图 4.2.3：残差正态检验

Shapiro-Wilk normality test 检验的 P 值显著小于 0.05，序列的残差不是正态分布，模型的残差似乎还蕴含更多信息，考虑进行 ARCH 效应检验与建模。

4.3. 参数显著性检验

```
> t1=-0.6551/0.1084
> pt(t1,df=69,lower.tail = T)
[1] 3.422543e-08
> t2=-0.7242/0.1099
> pt(t2,df=69,lower.tail = T)
[1] 3.655977e-09
> t3=-0.3708/0.1655
> pt(t3,df=69,lower.tail = T)
[1] 0.01414103
```

图 4.3.1：参数显著性检验
三个参数的 P 值都显著小于 0.05，因此三个参数都显著不为 0。

五. ARIMA模型预测

5.1. 模型预测

```
> x.fore=forecast(model1,h=5)
> x.fore
      Point Forecast      Lo 80      Hi 80      Lo 95      Hi 95
75      1077.7842    -769.8411  2925.410  -1747.915  3903.483
76      1037.4670   -2058.9628  4133.897  -3698.114  5773.048
77       721.9446   -3306.4900  4750.379  -5439.014  6882.904
78       319.5600   -4836.1792  5475.299  -7565.463  8204.583
79       173.3906   -6287.4641  6634.245  -9707.634 10054.415
```

图 5.1.1：未来 5 天无症状感染者预测




图 5.1.2：未来 5 天无症状感染者预测图




图 5.1.3：上下 95%置信区间

六. 对残差建立条件异方差模型

6.1 观察集群效应




图 6.1.1：残差平方时序图

显然 30-60 时期的波动显著大于其它时期，因此猜测存在集群效应。

6.2. ARCH 效应检验


```

> for(i in 1:5)
+   print(Box.test(residuals(model1)^2,lag=i))

Box-Pierce test

data: residuals(model1)^2
X-squared = 1.6212, df = 1, p-value = 0.2029

Box-Pierce test

data: residuals(model1)^2
X-squared = 2.2397, df = 2, p-value = 0.3263

Box-Pierce test

data: residuals(model1)^2
X-squared = 9.2138, df = 3, p-value = 0.02658

Box-Pierce test

data: residuals(model1)^2
X-squared = 10.175, df = 4, p-value = 0.03758

Box-Pierce test

data: residuals(model1)^2
X-squared = 10.313, df = 5, p-value = 0.06683

```

图 6.2.1: Portmanteau Q 检验

延迟阶数为 3, 4 时的 Portmanteau Q 检验的 P 值小于 0.05, 因此残差序列存在短期的自相关性, 存在 ARCH 效应

6.3. 确定条件异方差模型

```

Model:
GARCH(0,1)

Residuals:
      Min       1Q   Median       3Q      Max
-3.38461 -0.09363  0.04481  0.31416  3.20665

Coefficient(s):
      Estimate Std. Error t value Pr(>|t|)
a0 1.947e+06   3.063e+05   6.357 2.05e-10 ***
a1 4.513e-01   2.735e-01   1.650  0.099 .

```

图 6.3.1: ARCH(1) 模型

```

GARCH(0,2)

Residuals:
      Min       1Q   Median       3Q      Max
-3.47959 -0.12307  0.04877  0.33075  3.31730

Coefficient(s):
      Estimate Std. Error t value Pr(>|t|)
a0 1.845e+06   2.862e+05   6.445 1.15e-10 ***
a1 4.043e-01   2.666e-01   1.517  0.129
a2 1.260e-08   1.694e-01   0.000  1.000

```

图 6.3.2: ARCH(2) 模型

```

Model:
GARCH(0,3)

Residuals:
      Min       1Q   Median       3Q      Max
-3.60248 -0.09272  0.05300  0.31498  3.22208

Coefficient(s):
      Estimate Std. Error t value Pr(>|t|)
a0 1.742e+06   3.034e+05   5.744 9.27e-09 ***
a1 1.635e-01   3.797e-01   0.431  0.667
a2 1.324e-08   2.353e-01   0.000  1.000
a3 4.083e-01   3.571e-01   1.143  0.253

```

图 6.3.3: ARCH(3) 模型

```

Model:
GARCH(0,4)

Residuals:
      Min       1Q   Median       3Q      Max
-2.86455 -0.09696  0.05488  0.33730  2.94802

Coefficient(s):
      Estimate Std. Error t value Pr(>|t|)
a0 1.640e+06   5.981e+05   2.742 0.00611 **
a1 1.418e-01   4.694e-01   0.302 0.76262
a2 2.611e-10   2.825e-01   0.000 1.00000
a3 3.685e-01   4.125e-01   0.893 0.37163
a4 2.997e-01   2.421e-01   1.238 0.21560

```

图 6.3.4: ARCH(4) 模型

除了 ARCH(1), 其他模型都有参数不显著且接近 0, 所以选择 ARCH(1) 模型。

```
Diagnostic Tests:
  Jarque Bera Test

data:  Residuals
X-squared = 97.136, df = 2, p-value < 2.2e-16

Box-Ljung test

data:  Squared.Residuals
X-squared = 0.010776, df = 1, p-value = 0.9173
```

图 6.3.5: ARCH(1) 模型统计量

Jarque Bera 检验表明 ARCH(1) 模型的残差非正态, 而 Box-Ljung 检验结果表明残差的平方是白噪声序列。

七. 对序列建立条件异方差模型

7.1 检验集群效应




图 7.1.1: 平方时序图

观察平方时序图可知, 序列在中间部分的波动很大, 显著的大于两侧, 因此猜测存在集群效应

7.2 ARCH 检验

```

> for(i in 1:5)
+   print(Box.test(df2^2,lag=i))

Box-Pierce test

data:  df2^2
X-squared = 15.39, df = 1, p-value = 8.745e-05

Box-Pierce test

data:  df2^2
X-squared = 18.888, df = 2, p-value = 7.915e-05

Box-Pierce test

data:  df2^2
X-squared = 24.917, df = 3, p-value = 1.607e-05

Box-Pierce test

data:  df2^2
X-squared = 25.122, df = 4, p-value = 4.754e-05

Box-Pierce test

data:  df2^2
X-squared = 25.836, df = 5, p-value = 9.603e-05

```

图 7.2.1: LM 检验

```

> for(i in 1:5)
+   print(Box.test(df2^2,lag=i))

Box-Pierce test

data:  df2^2
X-squared = 15.39, df = 1, p-value = 8.745e-05

Box-Pierce test

data:  df2^2
X-squared = 18.888, df = 2, p-value = 7.915e-05

Box-Pierce test

data:  df2^2
X-squared = 24.917, df = 3, p-value = 1.607e-05

Box-Pierce test

data:  df2^2
X-squared = 25.122, df = 4, p-value = 4.754e-05

Box-Pierce test

data:  df2^2
X-squared = 25.836, df = 5, p-value = 9.603e-05

```

图 7.2.2: Portmanteau Q 检验

LM 检验与 Portmanteau Q 检验显示 1 阶至 5 阶 ARCH 模型均显著成立。

7.3 拟合 ARCH 模型

```
Model:
GARCH(0,1)

Residuals:
      Min        1Q      Median        3Q      Max
-2.205468 -0.261547 -0.003806  0.195383  2.715504

Coefficient(s):
      Estimate Std. Error  t value Pr(>|t|)
a0 3.382e+06   7.164e+05   4.721 2.35e-06 ***
a1 9.795e-01   7.552e-01   1.297  0.195
```

图 7.3.1: ARCH(1) 模型

```
Model:
GARCH(0,2)

Residuals:
      Min        1Q      Median        3Q      Max
-2.266420 -0.301858 -0.002235  0.205798  2.800585

Coefficient(s):
      Estimate Std. Error  t value Pr(>|t|)
a0 3.204e+06   6.480e+05   4.944 7.64e-07 ***
a1 7.547e-01   6.532e-01   1.155  0.248
a2 4.790e-09   1.937e-01   0.000  1.000
```

图 7.3.2: ARCH(2) 模型

```
Model:
GARCH(0,3)

Residuals:
      Min        1Q      Median        3Q      Max
-2.190327 -0.367226 -0.006323  0.214279  2.703823

Coefficient(s):
      Estimate Std. Error  t value Pr(>|t|)
a0 3.026e+06   8.254e+05   3.666 0.000246 ***
a1 4.418e-01   3.839e-01   1.151 0.249792
a2 1.585e-08   2.696e-01   0.000 1.000000
a3 1.879e-01   3.313e-01   0.567 0.570682
```

图 7.3.3: ARCH(3) 模型

```

Model:
GARCH(0,4)

Residuals:
      Min       1Q   Median       3Q      Max
-2.294299 -0.394908 -0.008885  0.225259  2.869105

Coefficient(s):
      Estimate Std. Error  t value Pr(>|t|)
a0 2.848e+06   7.160e+05   3.978 6.95e-05 ***
a1 1.965e-01   1.269e-01   1.549  0.121
a2 5.612e-02   1.975e-01   0.284  0.776
a3 1.104e-01   2.366e-01   0.466  0.641
a4 8.076e-09   1.796e-01   0.000  1.000

```

图 7.3.4: ARCH(4) 模型

```

GARCH(0,5)

Residuals:
      Min       1Q   Median       3Q      Max
-2.34263 -0.38867 -0.01162  0.23539  2.55088

Coefficient(s):
      Estimate Std. Error  t value Pr(>|t|)
a0 2.670e+06   8.420e+05   3.171 0.00152 **
a1 2.131e-01   1.421e-01   1.499 0.13375
a2 5.289e-02   2.084e-01   0.254 0.79968
a3 1.097e-01   2.663e-01   0.412 0.68042
a4 5.771e-08   2.089e-01   0.000 1.00000
a5 8.728e-02   1.352e-01   0.646 0.51854

```

图 7.3.5: ARCH(5) 模型

虽然以上模型都有参数不显著，但考虑到除了 ARCH(1) 模型外的其它 ARCH 模型都有接近 0 的参数，所以选择 ARCH1 模型。

7.4. ARCH 模型预测

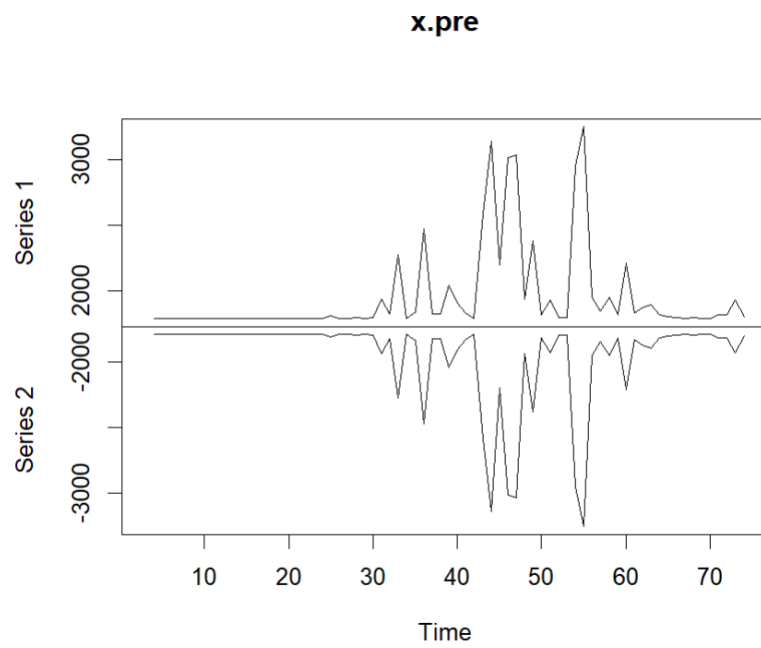


图 7.4.1: ARCH(1) 模型 95%置信区间




图 7.4.2: 条件异方差与方差齐性置信区间比较

据上图可知，条件异方差模型拟合的置信区间比无条件方差两条平行线给出的 95%的置信区间更加符合原序列的真实波动情况

附录：

```
1. library(tseries)
2. library(forecast)
3. library(lmtest)
4. library(zoo)
5. library(FinTS)
6. library(xlsxjars)
7. library(rJava)
8. library(xlsx)
9. #导入数据
10. mydata <- read.xlsx("D:\\MathModeling\\RFunction\\上海新增 3.1-
    5.13.xlsx",1)
11. no_sym <- mydata[,3]
12. no_sym=ts(no_sym,start=1)
13. #画图观察,显然非平稳
14. plot(no_sym,type='o',ylab=expression(无症状感染者),xlab=expression(时
    间),main=expression(无症状感染者时序图))
15. #一阶差分作图观察,单位根检验( $p=0.1724>0.05$ ),不平稳
16. plot(diff(no_sym),type='o',ylab=expression(一阶差分无症状感染
    者),xlab=expression(时间),main=expression(一阶差分无症状感染者时序图))
17. adf.test(diff(no_sym))
18. #二阶差分,单位根检验( $p=0.01<0.05$ ),平稳
19. plot(diff(diff(no_sym)),type='o',ylab=expression(二阶差分无症状感染
    者),xlab=expression(时间),main=expression(二阶差分无症状感染者时序图))
20. adf.test(diff(diff(no_sym)))
21. df2=diff(diff(no_sym))
22. #白噪声检验( $p=0.005646<0.05$ ),不是白噪声序列
23. for(i in 1:3)
24.   print(Box.test(df2),lag=6*i,type='Ljung-Box')
25. #拟合模型
26. acf(df2)
27. pacf(df2)
28. model1=arima(no_sym,order=c(2,2,3),transform.pars=F,
29.               fixed=c(NA,NA,0,0,NA))
30.
31. #画出残差图
32. plot(model1$residual,type='o')
33. abline(h=0)
34. #对残差进行白噪声检验( $p=0.95$ ),通过检验,是白噪声
35. for(i in 1:3)
36.   print(Box.test(model1$residual,lag=6*i))
37. #正态 QQ 图
38. hist(rstandard(model1),xlab='Standardlized~~Resiuals')
39. qqnorm(residuals(model1))
```



```
40. qqline(residuals(model1))
41. #残差性质图
42. tsdiag(model1)
43. #Portmanteau Q 检验
44. for(i in 1:3)
45.   print(Box.test(residuals(model1),lag=i))
46. #对残差建立 GARCH 模型
47. res.fit <- garch(model1$residuals,oreder=c(0,1))
48. #预测并画出预测图
49. x.fore=forecast(model1,h=5)
50. x.fore
51. plot(x.fore)
52. no_sym.fore=forecast(model1,h=5)
53. L1=no_sym.fore$fitted-1.96*sqrt(model1$sigma2)
54. U1=no_sym.fore$fitted+1.96*sqrt(model1$sigma2)
55. L2=ts(no_sym.fore$lower[,2],start=1)
56. U2=ts(no_sym.fore$upper[,2],start=1)
57. c1=min(no_sym,L1,L2)
58. c2=max(no_sym,L1,L2)
59. plot(no_sym,type='p',pch=8)
60. lines(no_sym.fore$fitted,col=2,lwd=2)
61. lines(no_sym.fore$mean,col=2,lwd=2)
62. lines(L1,col=4,lty=2)
63. lines(U1,col=4,lty=2)
64. lines(L2,col=4,lty=2)
65. lines(U2,col=4,lty=2)
66. #对参数进行显著性检验
67. t1=-0.6551/0.1084
68. pt(t1,df=69,lower.tail = T)
69. t2=-0.7242/0.1099
70. pt(t2,df=69,lower.tail = T)
71. t3=-0.3708/0.1655
72. pt(t3,df=69,lower.tail = T)
73. #残差分析
74.
75. #残差相关性质图
76. win.graph(width=6.5,height=6)
77. tsdiag(model1)
78. #残差分布
79. hist(residuals(model1))
80. #正态检验
81. qqnorm(residuals(model1))
82. qqline(residuals(model1))
83. #聚集效应
```

```
84. plot(df2^2,type='o')
85. #LM 检验
86. for (i in 1:5)
87.   print(ArchTest(df2),lag=i)
88. #Portmanteau Q 检验
89. for(i in 1:5)
90.   print(Box.test(df2^2,lag=i))
91.
92.
93. #建立条件异方差模型
94. model2=auto.arima(no_sym)
95. for(i in 1:5)
96.   print(Box.test(residuals(model1)^2,lag=i))
97. for (i in 1:3)
98.   print(ArchTest(residuals(model1),lag=i))
99. eacf(abs(residuals(model2)))
100. eacf(abs(residuals(model1)^2))
101. plot(residuals(model1)^2,type='o')
102. r.fit1 <- garch(model1$residuals,order=c(0,1))
103. summary(r.fit1)
104.
105. r.fit2 <- garch(model1$residuals,order=c(0,2))
106. summary(r.fit2)
107.
108.
109. r.fit3 <- garch(model1$residuals,order=c(0,3))
110. summary(r.fit3)
111.
112. r.fit4 <- garch(model1$residuals,order=c(0,4))
113. summary(r.fit4)
114.
115. r.fit5 <- garch(model1$residuals,order=c(0,2))
116. summary(r.fit5)
117.
118. plot(residuals(r.fit5),type='o')
119. acf(residuals(r.fit5)^2,na.action=na.omit)
120. gBox(r.fit5,method='squared')
121.
122. eacf(abs(diff(diff(no_sym))))
123. model2=garch(x=diff(no_sym),order=c(0,3))
124. qqnorm(residuals(model2))
125. qqline(residuals(model2))
126. shapiro.test(na.omit(residuals(model2)))
127. #Arch 模型
```

```
128. df2.fit1 <- garch(df2,order=c(0,1))
129. summary(df2.fit1)
130.
131. df2.fit2 <- garch(df2,order=c(0,2))
132. summary(df2.fit2)
133.
134. sumdf2.fit3 <- garch(df2,order=c(0,3))
135. summary(df2.fit3)
136.
137. df2.fit4 <- garch(df2,order=c(0,4))
138. summary(df2.fit4)
139.
140. df2.fit5 <- garch(df2,order=c(0,5))
141. summary(df2.fit5)
142.
143. df2.fit1 <- garch(df2,oreder=c(1,1))
144. summary(df2.fit1)
145. x.fit <- garch(df2,oreder=c(0,1))
146. #绘制波动置信区间
147. x.pre <- predict(x.fit)
148. plot(x.pre)
149. #对比
150. plot(df2)
151. lines(x.pre[,1],col=2)
152. lines(x.pre[,2],col=2)
153. abline(h=1.96*sd(df2),col=4,lty=2)
154. abline(h=-1.96*sd(df2),col=4,lty=2)
```